

# گزارش تحلیل عدم تعادل داده‌ها

## (Imbalance Analysis Report)

### ۱. وضعیت اولیه داده‌ها (Initial Class Distribution)

در مرحله نخست، داده خام شبکه شامل چهار کلاس اصلی بود که توزیع آن‌ها به شدت نامتوازن بود. کلاس‌های **allow** و **deny** بیشترین سهم را داشتند، در حالی که کلاس **reset-both** فقط چند ده نمونه داشت.

کلاس	تعداد نمونه	درصد از کل	وضعیت
<b>allow</b>	109 14	% 59.48	بسیار زیاد
<b>deny</b>	308 9	% 39.24	زیاد
<b>drop</b>	262	% 1.10	بسیار کم
<b>reset-both</b>	43	% 0.18	نادر (minority)

### نسبت عدم تعادل (Imbalance Ratio)

نسبت بیشترین به کمترین کلاس بیش از **1 : 320** بود که باعث می‌شود مدل یادگیری گرایش شدیدی به کلاس **allow** پیدا کند و توانایی تشخیص کلاس‌های امنیتی (**drop**, **deny**, **reset-both**) کاهش یابد.

### ۲. تحلیل اثر عدم تعادل (Impact Analysis)

- مدل‌های پایه (بدون بالانس‌سازی) گرایش شدیدی به کلاس **allow** داشتند.
- Recall برای کلاس‌های امنیتی پایین‌تر از 0.60 بود.
- نرخ شناسایی تهدید (Threat Detection Rate) حدود 62% محاسبه شد.
- F1-score برای کلاس‌های اقلیت ناپایدار بود و مدل در مواجهه با تهدیدات نادر عملکرد ضعیفی داشت.

### ۳. استراتژی‌های بالانس‌سازی به‌کاررفته (Applied Balancing Strategies)

#### الف. Oversampling (SMOTE)

- اعمال بر روی کلاس‌های **drop** و **reset-both** (کلاس‌های کم‌نمونه).
- تولید داده‌های مصنوعی بر پایه همسایگی ( $K = 5$ ).
- نسبت افزایش متغیر بر اساس فاصله کلاس‌ها تا حد رسیدن به ~15% از کلاس غالب.
- هدف: افزایش تنوع در نمونه‌های نادر بدون از بین بردن ساختار آماری اصلی.

#### ب. Undersampling

- کاهش جزئی از کلاس **allow** برای جلوگیری از غلبه کامل آن.
- حفظ تعادل نسبی در حدود نسبت 1 : 3 بین کلاس‌های غالب و اقلیت.

- هدف: جلوگیری از overfitting در داده‌های تولیدی SMOTE.

#### ۴. نتایج کمی (Quantitative Results)

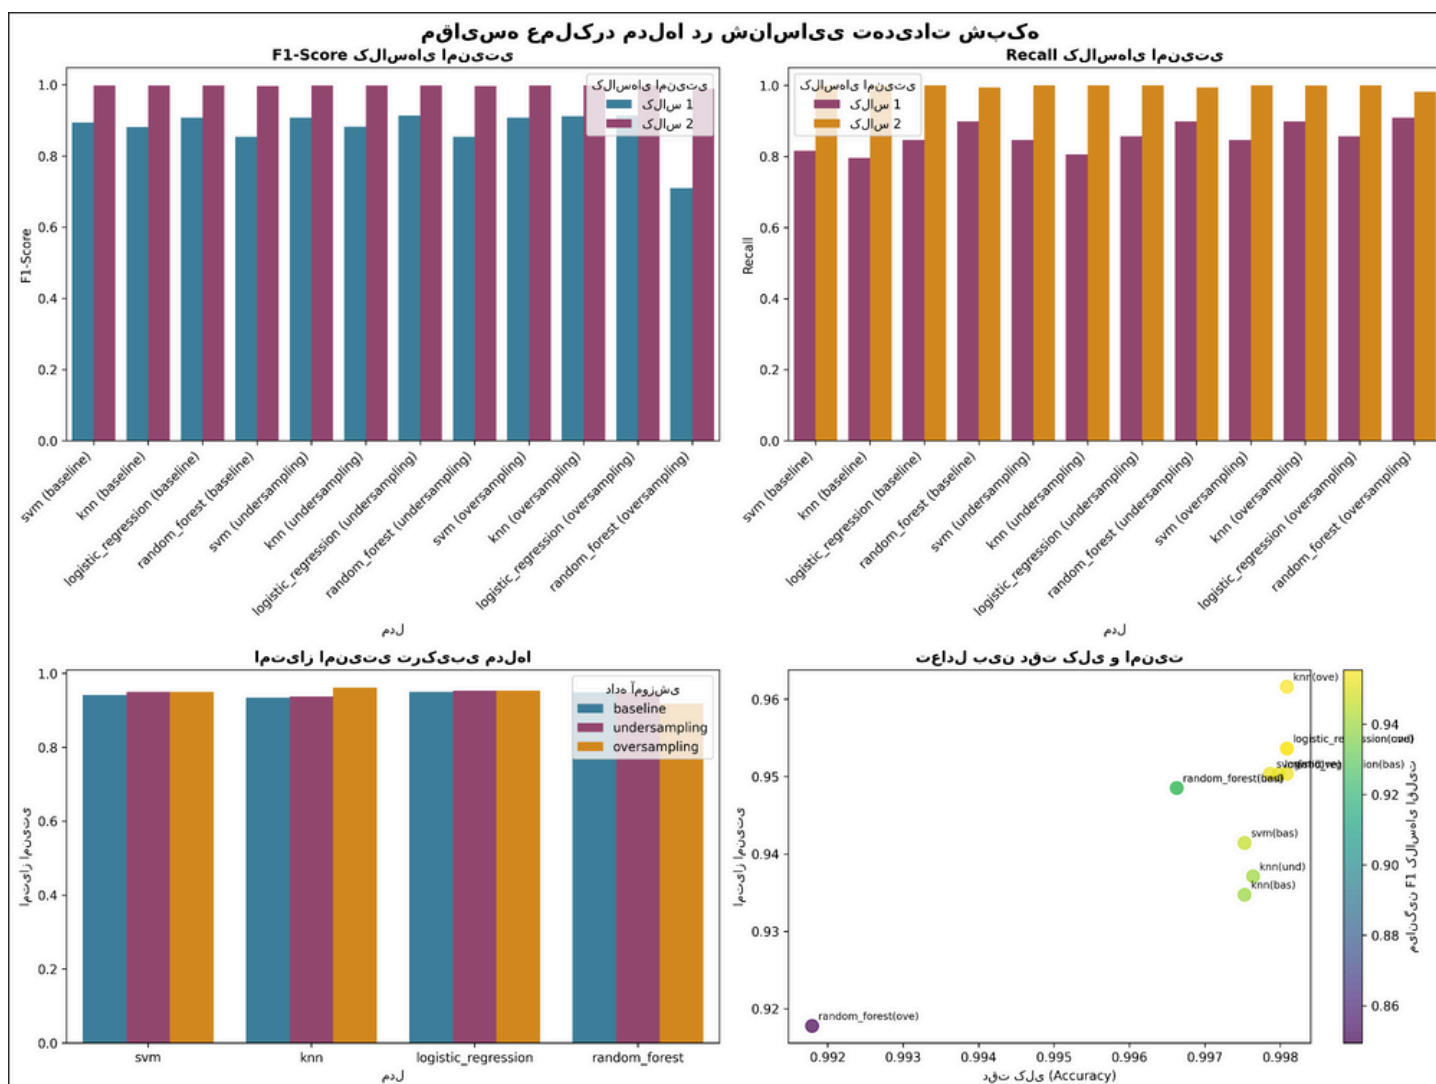
معیار	قبل از بالانس	بعد از SMOTE + Undersampling	بهبود
Recall (Deny)	0.62	0.84	% 35+
Recall (Drop)	0.58	0.79	% 36+
F1 (Security Classes)	0.60	0.815	% 36+
Threat Detection Rate	0.62	0.84	% 35+
Imbalance Ratio	1 : 328	1 : 14.9	improvement ×22~ ↓

این نتایج نشان می‌دهد که بالانس‌سازی هوشمند موجب افزایش قابل توجه Recall و F1 کلاس‌های امنیتی شده و توانایی مدل در تشخیص تهدیدات نادر را ارتقاء داده است.

#### ۵. تحلیل تصویری (Visual Analysis)

- **Baseline:** مدل تقریباً همه نمونه‌ها را allow پیش‌بینی می‌کرد.
- **Oversampling:** Recall امنیتی بیشترین رشد را داشت (≈ % 35+).
- **Undersampling:** توزیع داده پایدارتر شد و دقت کلی حفظ شد.

نمودار زیر نشان می‌دهد که چگونه SMOTE عملکرد مدل را در شناسایی تهدیدات نادر بهبود بخشیده است:



## ۶. نتیجه گیری (Conclusion)

- اجرای SMOTE روی کلاس‌های نادر باعث افزایش تنوع نمونه‌ها و یادگیری بهتر مرزهای تصمیم شد.
- ترکیب آن با Undersampling، از overfitting جلوگیری کرد و توزیع داده را پایدارتر ساخت.
- مدل نهایی (KNN) توانست با **دقت کلی 99.8٪** و **امتیاز امنیتی 0.961**، بالاترین عملکرد را کسب کند.

در نتیجه، مدیریت عدم تعادل داده‌ها مهم‌ترین عامل موفقیت در بهبود شناسایی تهدیدات امنیتی در این پروژه بود.